In []:

#L'azienda Y produce viti che devono essere lunghe 100 mm. La lunghezza delle viti segue una distr normale con una std

#(dev standard) della popolazione = 2.

#Le macchine che producono viti devono essere ricalibrate una volta a settimana, e si dov rà quindi controllare se la macchina

#è correttamente calibrata nel produrre viti da 100 mm di lunghezza. Basandoti su un samp le di 20 viti, ottieni una lunghezza

#media di 100.929 mm. Testa con un lvl di 2% significatività se la macchina è correttamen te calibrata o corrotta.

#Calcola il p-value e la z-statistic.

#L'ipotesi nulla H0 è che la lunghezza media prodotta dalla macchina sia 100, l'ipotesi a lternativa H1 è che sia diversa da 100.

#Se non accetto l'ipotesi nulla, l'implicazione che la macchina sia corrotta e produca me diamente viti diverse da 100 è vera.

#Quindi supponendo che la lunghezza delle viti seguano una curva normale, uso una confide nza del 98% sulla curva normale

#con l'assunzione che la media interna all'intervallo sia quello dell'ipotesi nulla HO.

#Se la sample mean è fuori quest'intervallo, ho il 2% di probabilità, quindi una probabil ità bassa che l'ipotesi nulla sia vera, quindi le macchine

#producano viti da 100 mm di lunghezza media, pur avendo una media del campione delle vit i fuori dall'intervallo di confidenza.

#Quindi in questo caso, data la bassa probabilità del 2% di avere una sample mean fuori l 'intervallo di confidenza del 98%

#pur avendo una ipotesi nulla vera, rifiuto l'ipotesi nulla. Se la sample mean fosse all' interno dell'intervallo di confidenza,

#ho il 2% di probabilità di commettere un errore, ovvero sia che la sample mean sia all'i nterno dell'intervallo di confidenza,

#anche se la macchina produce viti che hanno una media diversa da 100 mm. In questo caso n on rifiuterei l'ipotesi nulla, e

#avrei una confidenza del 98% di non commettere un errore assumendo che la macchina produ ca viti di 100mm in media.

In []:

#qual è quindi il lvl di significatività migliore? l'errore di tipo 1, indica la prob di rifiutare l'ipotesi nulla quando

è vera (la media di 100). Se l'intervallo di conf è al 90%, la prob di rifiutare l'ipot esi nulla è 10% se la sample mean

#è fuori l'intervallo. D'altra parte, diminuire il lvl di significatività, quindi aumenta re il lvl di confidenza del tipo,

avere diminuire il livello di significatività al 5%, aumentando dunque l'intervallo di conf al 95%, aumenta la prob

#dell'errore di tipo 2, cioè non rigettare l'ipotesi nulla quando è falsa ed è vera Ha. #Cioè l'intervallo di conf più alto

#aumenta la prob di NON rigettare l'ipotesi nulla, quindi per rigettare l'ipotesi nulla i n questo caso dobbiamo avere

#molti campioni estremi con medie estreme, perché l'intervallo

è più largo, E quindi è più difficoltoso provare che la pop sia veramente di 100, perch é noi effettivamente stiamo

aumentando l'intervallo di confidenza e il range in cui potrebbe essere, quindi ho più probabilità di accettare HO.

#Quindi: se accetto H0, e H0 è vera, conclusione corretta. Se non rifiuto H0, ma è vera H a, c'è l'errore di tipo 2.

#se rifiuto HO, e HO è vera, errore di tipo 1. Se rifiuto HO, ma è vera Ha, conclusione c orretta.

In []:

#qual è il lvl di significatività migliore? dipende. C'è un trade off in questo caso, o p rodurre viti troppo lunghe/corte,

#o stoppare le macchine per ricalibrare (che può costare). Più è alto il lvl di significa tività e quindi basso l'intervallo

#di conf, più si sta aumentando la prob di rigettare l'ipotesi nulla e quindi di ricalibr are le macchine, perché il sample mean

```
ltra parte, più abbassi il lvl di
#significatività e dunque aumentando il lvl di confidenza, più si sta abbassando la prob
di rigettare l'ipotesi nulla e
#quindi aumentando la prob di avere viti diverse da 100, perché in questo caso l'interval
lo di confidenza sarebbe più ampio,
#e per rifiutare l'ipotesi nulla e dunque accettare l'ipotesi che il macchinario sia corr
otto e non produca viti da 100mm
#in media, occorrerebbe avere dei campioni che abbiano medie estreme che ricadano fuori l
'intervallo di confidenza più largo,
#pure nell'occasione che la macchina produca effettivamente viti troppo lunghe/corte.
In [1]:
import numpy as np
import scipy.stats as stats
import matplotlib.pyplot as plt
In [2]:
#la macchina corrotta produce viti con
mu = 100.7 \#unknown
pop_std = 2 \#known
In [3]:
sample size = 20
#sappiamo che le viti sono normalmente distribuite. Se quindi la pop è normalmente distri
buita, allora non importa la sample
#size anche ogni campione sarà normalmente distribuito.
In [4]:
#creo il sample di 20 normalmente distribuito
np.random.seed(123)
sample = np.random.normal(loc = mu, scale = pop std, size = sample size)
sample
Out[4]:
array([ 98.52873879, 102.69469089, 101.265957 , 97.68741057,
        99.5427995 , 104.00287307, 95.84664151, 99.84217474,
       103.23187252,
                     98.9665192 , 99.3422277 , 100.51058206,
       103.68277925, 99.42219601, 99.81203608, 99.83129745,
       105.11186017, 105.07357218, 102.7081078 , 101.4723728 ])
In [5]:
point est mean = sample.mean()
point est mean
#il punto di stima della media della popolazione è uguale alla media del campione
Out[5]:
100.92883546391059
In [6]:
std error = pop std / np.sqrt(sample size)
std error
Out[6]:
0.4472135954999579
In [7]:
H0 = 100
```

#pongo l'ipotesi nulla uquale a 100, ovvero che il macchinario produca viti da 100mm in m

#sarebbe fuori l'intervallo di conf quindi dirai che la pop mean sarà diversa da 100. D'a

```
edia.
# HO -> ipotesi nulla = 100
# Ha != 100 -> cioè la vera media è diversa da 100.
In [8]:
conf = 0.90
#scelgo una confidenza del 90%
In [9]:
#creo l'intervallo di conf al 90%
stats.norm.interval(conf, loc = H0, scale = std error)
# sto quindi assumendo che la vera media sia 100
#vediamo che però la sample mean è fuori questo intervallo
Out[9]:
```

(99.26439909541989, 100.73560090458011)

In []:

#la sample mean è fuori l'intervallo, quindi è molto probabile che l'ipotesi nulla sia da rigettare. #anche se sappiamo per ipotesi, anche non conosciuta, il macchinario sia effettivamente c orrotto e produca viti di 100.7 mm.

In [10]:

```
x = np.linspace(96, 104, 1000) #metto mille valori tra 96 e 104
y = stats.norm.pdf(x, loc = H0, scale = std error)
```

In [16]:

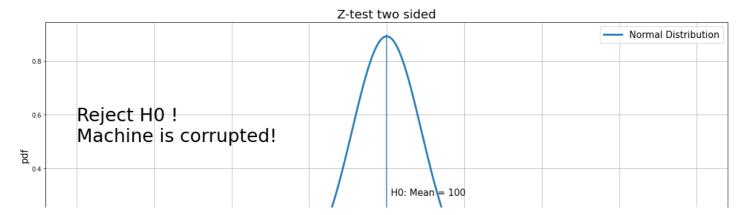
```
left, right = stats.norm.interval(conf, loc = H0, scale = std error)
```

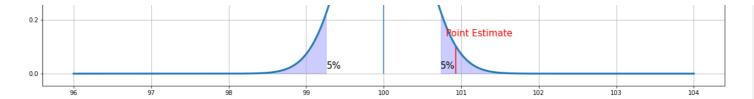
In [19]:

```
plt.figure(figsize = (20, 8))
plt.plot(x, y, linewidth = 3, label = "Normal Distribution")
plt.vlines(x = H0, ymin = 0, ymax = 0.90)
plt.vlines(x = point est mean, ymin = 0, ymax = 0.1, color = "red")
plt.fill_between(x, y, where = ((x > right) | (x < left)), color = "blue", alpha = 0.2)
plt.annotate("5%", xy = (100.73, 0.02), fontsize = 15)
plt.annotate("5%", xy = (99.26, 0.02), fontsize = 15)
plt.annotate('Reject H0 !\nMachine is corrupted!', xy = (96, 0.5), fontsize = 30)
plt.annotate("H0: Mean = 100", xy = (100.05, 0.3), fontsize = 15)
plt.annotate("Point Estimate", xy = (100.8, 0.14), color = "red", fontsize = 15)
plt.grid()
plt.title("Z-test two sided", fontsize = 20)
plt.ylabel("pdf", fontsize = 15)
plt.legend(fontsize = 15)
```

Out[19]:

<matplotlib.legend.Legend at 0x24785435d60>





In [20]:

#il point of estimate è fuori l'intervallo di conf, quindi si rigetta l'ipotesi nulla e l a macchina è corrotta perché non

#produce viti (popolazione) di media 100

#Nota bene: usiamo distr normale perché sappiamo la varianza della popolazione, altriment i la distribuzione da usare

è una t-student

In [21]:

#Dato un livello di confidenza del 90%, il punto di stima della media è fuori l'intervall o di confidenza con media 100, cioè

abbiamo il 10% di probabilità di avere dei valori fuori l'intervallo di confidenza, dat o che comunque il macchinario produca

effettivamente viti da 100 mm in media.

#Se aumentassi il lvl di confidenza, ad esempio al 98%, la media del sample ricadrebbe ne ll'intervallo di confidenza, pur avendo

#una macchina che produce viti con una media diversa da 100 mm, dunque corrotta.

In [22]:

#Calcolo il p-value

#spiegazione teorica p-value: è la probabilità che il possibile rifiuto dell'ipotesi null a sia solo dovuto al caso.

#poniamo il caso di voler verificare che il reddito medio delle famiglie di milano sia si gnificativamente diverso da 1500 euro.

#poniamo il caso di aver estratto un campione che casualmente è constituito dalle famigli e più ricche di milano. In questo caso

#avremmo che il campione avrebbe un reddito medio significativamente maggiore di 1500 eur o, e dunque cadrebbe fuori

#1'intervallo di confidenza, dunque rifiuteremo l'ipotesi nulla. Ma questo rifiuto è solo dovuto al caso, in quanto

#1'universo è costituito sia da famiglie povere che medie che ricche, ma casualmente il m io campione ha pescato solo famiglie

#ricche. Quindi il mio p value mi dice che il possibile rifiuto dell'ipotesi nulla sia do vuto alla casualità del campione

#che ho estratto che non rispecchia la situazione dell'universo.

#Calcolo p value in pratica: è la probabilità di osservare valori più estremi della stati stica test osservata.

#Poniamo caso nel nostro test d'ipotesi abbiamo la media del campione che cade nella regi one di non rifiuto, e il valore

#essendo un test unilaterale sx è z=-1.68. Quindi valori più estremi significa valori i nferiori a -1.68.

 $\#Quindi\ il\ p\ value\ sarebbe\ l'area\ che\ va\ da\ meno\ infito\ a\ -1.68.$ In questo caso sarebbe il p\ value\ sarebbe\ 0.0465.

#Se il p value è > del lvl di significatività, allora non rifiuto l'ipotesi nulla, altrim enti rifiuto.

#Se il lvl di significatività è 1%, cioè 0.01 con un intervallo di confidenza del 99%, al lora rifiuto l'ipotesi nulla.

#se vi è una Bilaterale, allora il p value si calcola come l'area a dx del point of estim ate, moltiplicato a due, dove

#il point of estimate per calcolarne l'area si prende sempre negativo, e poi moltiplico due.

In [23]:

0 1 5001

```
z_stat = (point_est_mean - H0) / std_error
z stat
```

#calcolo la z-statistic, che ci dice in questo caso che la media del sample è 2 std_error lontano dalla media

```
stats.norm.cdf(-abs(z stat))
#calcola la prob della coda. Se metto meno, calcola la prob della coda a sx.
#sia che stia facendo una unilaterale a sx o dx, devo calcolare sempre il z stat col segn
o meno, perché mi serve l'area
#che va dalla z stat a infinito, sia esso che sia dx che sx, se metto col valore positivo
, anche in caso di unilaterale dx,
#io starei calcolando l'area che va da - infinito alla z-statistic a destra della media d
ell'ipotesi nulla.
Out[24]:
0.01890358386435081
In [25]:
p value = 2 * stats.norm.cdf(-abs(z stat))
p_value
# è la p delle due p sommate delle code. Lo faccio perché in questo caso sto facendo una
bilaterale.
Out[25]:
0.03780716772870162
In [26]:
#siccome il p-value < lvl di significatività, cioè 0.037 < 0.1, rifiuto l'ipotesi nulla.
```

Out[23]:

In [24]:

In []:

2.0769392372166267